ChatGPT 技術諮詢對話紀錄存證 (AI Assistance Dialogue)

專案主題：物聯網應用與資料分析 HW2 - King County 房價多元線性回歸與 CRISP-DM 實作
匯出工具：Direct PDF Render / pdfCrowd Equivalent | 對象：ChatGPT-4o | 學生學號：7114056XXX

[User 學生提問 - Step 1]
請協助我規劃 AIoT 課程 HW2 的多元線性回歸作業架構。作業要求：
1. 選擇 Kaggle 10~20 個特徵的資料集
2. 遵循 CRISP-DM 六大流程
3. 必須包含特徵選擇 (Feature Selection) 與模型評估 (Model Evaluation)
4. 必須繪製預測圖，並加上信賴區間 (CI) 或預測區間 (PI)
你有推薦的資料集與架構規劃嗎？

[ChatGPT-4o 技術回覆 - Step 1]
針對您的作業要求，強烈推薦選用 Kaggle 最經典的 **「House Sales in King County, USA (西雅圖房價資料集)」**：

1. **特徵維度完美契合**：原始欄位 21 個，扣除 ID 與 Date 後正好具備 18 個預測特徵（如室內坪數、土地坪數、樓層、水岸、景觀、屋況、建築評等、經緯度等），嚴格符合 10~20 個特徵之規定。
2. **CRISP-DM 流程規劃**：
- **Business Understanding**：設定智慧房產（PropTech / AIoT 智慧城市）自動化估價目標與可解釋性要求。
- **Data Understanding**：檢驗 21,613 筆交易紀錄、零缺失值確認、繪製 Pearson 相關係數熱力圖。
- **Data Preparation**：處理異常值（如 33 間臥室登錄筆誤），衍生屋齡 (house_age) 與翻修 (is_renovated) 特徵；**關鍵特徵選擇**：以 VIF (變異數膨脹因子) 抓出 sqft_living = sqft_above + sqft_basement 的完全共線性並剔除冗餘，再以 Lasso L1 正則化檢視權重。
- **Modeling**：實作 Full OLS、Selected OLS、Ridge (L2)、Lasso (L1) 及 Log-OLS。
- **Evaluation**：評估 R^2、RMSE、MAE、MAPE，繪製殘差診斷三合一圖 (殘差圖、Q-Q 圖、分佈圖)，並透過 statsmodels 計算 **95% 信賴區間 (CI)** 與 **95% 預測區間 (PI)** 繪製排序預測圖。
- **Deployment**：使用 joblib 序列化儲存 Pipeline，提供即時推論展示。

[User 學生提問 - Step 2]
在特徵選擇時，為什麼 King County 資料集的 sqft_living 會產生高達 10^15 的 VIF？我們應該如何進行特徵選擇並在報告中解釋？

[ChatGPT-4o 技術回覆 - Step 2]
這是一個極佳的計量經濟學展示案例！

1. **數學原因**：
在 King County 資料集中，建築結構關係為：
$$\text{sqft_living} = \text{sqft_above} + \text{sqft_basement}$$
這構成了嚴格的「完全共線性 (Perfect Multicollinearity)」。當三個特徵同時放入設計矩陣 X 時，矩陣 $X^T X$ 的行列式值趨近於 0（秩虧），導致 $VIF = \frac{1}{1-R^2}$ 爆增至 10^{15}。

2. **特徵選擇策略 (Feature Selection)**：
- **相關係數比對**：檢視與目標房價的 Pearson 相關性，發現 `sqft_living` 高達 0.70，而 `sqft_above` 為 0.61、`sqft_basement` 為 0.32。
- **決策**：保留綜合資訊量最大且與目標最相關的 `sqft_living`，主動剔除 `sqft_above` 與 `sqft_basement`；同時剔除與土地面積重疊的 `sqft_lot15`。
- **成效驗證**：剔除後重新計算 VIF，所有入選的 14 個特徵其 VIF 全數降至 5.06 以下（遠低於警戒值 10），模型測試集 R^2 幾乎毫無損失 (0.6956 降至 0.6944，僅微幅變動 0.0012)，大幅提升了模型係數的數值穩定性與經濟解釋力！

[User 學生提問 - Step 3]
作業要求結果必須提供「預測圖 (加上信賴區間或預測區間)」，請說明這兩者在統計學上的差別？如何用 Python 實現並畫在一張圖上？

[ChatGPT-4o 技術回覆 - Step 3]
「信賴區間 (Confidence Interval, CI)」與「預測區間 (Prediction Interval, PI)」是回歸分析中極易混淆但層次完全不同的統計觀念：

1. **95% 信賴區間 (CI for Mean Response, $E[Y|X=x_0]$)**：
$$\hat{y}_0 \pm t_{\alpha/2, n-p} \cdot s \sqrt{x_0^T (X^T X)^{-1} x_0}$$
- **意義**：估計「特徵條件為 x_0 之所有房屋的平均房價」。
- **特性**：僅包含回歸面估計的抽樣誤差。由於大樣本 ($n=17,289$) 下樣本量極大，其區間非常狹窄。

2. **95% 預測區間 (PI for Individual Observation, Y_0)**：
$$\hat{y}_0 \pm t_{\alpha/2, n-p} \cdot s \sqrt{1 + x_0^T (X^T X)^{-1} x_0}$$
- **意義**：預測「單一棟全新建造房屋」的成交房價。
- **特性**：除了回歸估計誤差外，還必須加上個別觀測值的內生隨機擾動 σ^2（即公式根號內的額外『$+1$』）。因此，**預測區間必然顯著寬於信賴區間**！

3. **Python 實現核心代碼**：
```python
pred = sm_ols.get_prediction(X_test_sm)
frame = pred.summary_frame(alpha=0.05)
# frame['mean_ci_lower'] ~ frame['mean_ci_upper'] 為 95% CI (窄光帶)
# frame['obs_ci_lower'] ~ frame['obs_ci_upper'] 為 95% PI (寬光帶)
```
繪圖時將測試樣本依預測值排序，用 `plt.fill_between` 疊加紅光帶 (CI) 與藍光帶 (PI)，並散點標記實際房價，視覺效果具備極高說服力！

[User 學生提問 - Step 4]
最後，請針對 Kaggle 上同資料集的更優解法（如 XGBoost/LightGBM）進行技術比較，並說明為什麼在某些實際場景下多元線性回歸依然是首選？

[ChatGPT-4o 技術回覆 - Step 4]
在 Kaggle 競賽中，頂尖參賽者對此資料集的解法演進如下：

1. **主流與更優解法 (GBDT & Ensemble)**：
- **演算法**：LightGBM, XGBoost, CatBoost。
- **特徵工程**：對目標房價做 $\ln(price)$ 對數變換；引入空間地理特徵（計算至西雅圖市中心的 Haversine 大圓距離、郵遞區號 Target Encoding）。
- **表現**：單一 GBDT 模型 R^2 可達 0.88~0.90，集成 Stacking 更可超越 0.915，RMSE 壓低至 10.5 萬美元以內。

2. **為什麼在許多實際產業場景下多元線性回歸依然不可替代？**：
- **嚴格金融與法律合規性**：在銀行房貸估價、政府不動產地價稅評估中，黑盒子模型（如深度神經網絡或深層決策樹）無法解釋個別特徵的定價權重，易引發歧視爭議。線性回歸每個係數 β_j 直接代表邊際價格（例如每多 1 平方英尺增值 $168 美元），具備法律可解釋性。
- **精確的解析區間推論**：線性回歸能直接導出解析的 95% CI 與 PI，為保險與風險準備金提供嚴謹的機率界限；樹模型只能透過昂貴的非參數 Bootstrap 逼近。
- **極致的邊緣推論算力優勢**：在 IoT 邊緣裝置上，線性回歸只需進行點積運算，毫秒級推論且記憶體占用近乎為零。